

DocuMind — Documento 2: Historias de Usuario (US)

Backlog del Producto y Especificación Ágil con Criterios de Aceptación BDD/Gherkin

Este documento formaliza los requisitos funcionales del sistema **DocuMind** utilizando la metodología ágil de **Historias de Usuario (US)**. Cada historia detalla la perspectiva del usuario (Analistas de áreas jurídicas, financieras y de selección de personal) y define de forma precisa los criterios de aceptación técnica bajo el formato BDD (Behavior-Driven Development / Given-When-Then). Esto garantiza la trazabilidad entre el problema operativo y la posterior implementación del código.

Módulo 1: Gestión de Repositorios e Ingesta Documental

HU-01: Carga Multiformato de Documentos	Prioridad: Alta Estimación: 5 SP
Como: Analista Operativo (Legal, Financiero o de Selección) Quiero: cargar archivos en formatos PDF, DOCX y TXT en el repositorio del sistema Para: que la plataforma extraiga el texto plano e inicie el pipeline de procesamiento inteligente automáticamente.	
Criterios de Aceptación (BDD / Gherkin):	
Escenario: Carga exitosa de un archivo admitido Dado que el usuario se encuentra autenticado en el sistema Cuando arrastra un archivo con extensión '.pdf', '.docx' o '.txt' de tamaño menor o igual a 15MB Entonces el sistema guarda el archivo de forma segura, cambia el estado a 'PENDIENTE' e inicia la extracción del texto. Escenario: Rechazo por formato o tamaño no soportado Dado que el usuario está en la interfaz de carga Cuando intenta subir un archivo con extensión '.exe' o un archivo '.pdf' que supera los 15MB de tamaño Entonces el sistema detiene la carga, muestra un mensaje de error explicativo en pantalla y bloquea el procesamiento.	

HU-02: Clasificación Automática mediante IA

Prioridad: Alta | Estimación: 8 SP

Como: DocuMind Backend Engine

Quiero: analizar el texto plano extraído del archivo recién subido mediante modelos de procesamiento de lenguaje natural

Para: clasificarlo automáticamente en una de las tres categorías principales de negocio: 'Contrato', 'Factura' o 'Hoja de Vida'.

Criterios de Aceptación (BDD / Gherkin):

Escenario: Clasificación exitosa con alta confianza

Dado un documento cuyo texto ya ha sido extraído correctamente en el pipeline

Cuando el motor de IA procesa el contenido mediante un modelo LLM usando zero-shot classification

Entonces se le asigna la categoría correspondiente (Contrato, Factura o Hoja de Vida) con un score de confianza superior al 80%.

Escenario: Manejo de documentos ambiguos

Dado un documento cargado cuyo texto no coincide razonablemente con ninguna de las tres categorías de negocio

Cuando el motor de IA calcula un score de confianza inferior al 80% para todas las opciones

Entonces el sistema etiqueta el archivo como 'Otros / Sin Clasificar', registra el log de advertencia y actualiza el Dashboard para revisión humana.

Módulo 2: Extracción Estructurada e Inteligencia Artificial

HU-03: Extracción de Metadatos Clave por Categoría	Prioridad: Alta Estimación: 8 SP
Como: Usuario Especialista (Analista Legal, Financiero o Reclutador) Quiero: que el sistema ejecute una extracción de metadatos personalizada según la categoría del archivo Para: visualizar los atributos clave estructurados en un formato limpio (JSON) sin necesidad de abrir ni leer manualmente el archivo completo.	
Criterios de Aceptación (BDD / Gherkin):	
Escenario: Extracción de atributos para 'Contratos' Dado un documento clasificado exitosamente como 'Contrato' Cuando el pipeline de extracción analiza el texto estructurando la salida Entonces extrae en formato JSON: Nombres de las partes firmantes, Fecha de vigencia y Cláusula de penalizaciones. Escenario: Extracción de atributos para 'Facturas' Dado un documento clasificado exitosamente como 'Factura' Cuando el pipeline de extracción analiza el texto estructurando la salida Entonces extrae en formato JSON: Emisor (NIT), Valor total, Impuestos aplicados y Fecha límite de pago. Escenario: Extracción de atributos para 'Hojas de Vida' Dado un documento clasificado exitosamente como 'Hoja de Vida' Cuando el pipeline de extracción analiza el texto estructurando la salida Entonces extrae en formato JSON: Tecnologías/habilidades clave, Años de experiencia y Último título académico obtenido.	
HU-04: Generación de Resumen Ejecutivo Sintético	Prioridad: Media Estimación: 5 SP
Como: Gerente de Operaciones Quiero: visualizar una síntesis ejecutiva automática y corta del documento Para: entender de forma rápida y concisa el propósito del archivo sin demoras operativas.	
Criterios de Aceptación (BDD / Gherkin):	
Escenario: Generación de resumen exitosa Dado un archivo procesado exitosamente por la plataforma Cuando el usuario accede al panel de detalle del documento Entonces el sistema muestra un resumen explicativo autogenerado por el LLM que no supera las 150 palabras.	

Módulo 3: Motor de Búsqueda Semántica y Chat Conversacional RAG

HU-05: Consulta en Lenguaje Natural sobre el Repositorio	Prioridad: Alta Estimación: 13 SP
Como: Analista de Negocio o Gerente de Área Quiero: hacer consultas directas en lenguaje natural (RAG) en un módulo de chat integrado Para: encontrar información cruzada, resolver dudas de cláusulas o resumir datos operativos de múltiples archivos a la vez.	
Criterios de Aceptación (BDD / Gherkin):	
Escenario: Consulta exitosa con coincidencia en documentos Dado que existen documentos vectorizados y almacenados en la base de datos vectorial Cuando el usuario ingresa la pregunta '¿Qué contratos vencen en el próximo mes?' o '¿Qué candidatos dominan Python?' Entonces el motor de búsqueda vectorial recupera los fragmentos (chunks) más relevantes de forma semántica y genera una respuesta precisa, citando el nombre exacto de los archivos origen. Escenario: Consulta sin información disponible Dado un repositorio documental activo Cuando el usuario realiza una pregunta sobre un tema del cual no hay información ni contexto en los archivos subidos Entonces el sistema responde de forma honesta indicando que la respuesta no se encuentra en las fuentes disponibles, evitando generar alucinaciones.	