

DOCUMIND — DICCIONARIO DE DATOS

Especificación técnica de persistencia de datos (MySQL Relacional & Pinecone Vectorial)

1. Introducción al Modelo de Persistencia Híbrido

El modelo de datos de **DocuMind V1.0** está optimizado para resolver el reto empresarial planteado por las Unidades Tecnológicas de Santander (UTS): transformar un repositorio de almacenamiento pasivo en un repositorio inteligente. El sistema aprovecha una **estrategia de persistencia híbrida** que combina de forma óptima una base de datos relacional (**MySQL**, administrada mediante **HeidiSQL**) para las transacciones estructuradas y el control de negocio, y una base de datos vectorial (**Pinecone DB**) para el motor semántico conversacional (RAG) alimentado por la API de Google Gemini.

Ventaja Clave de MySQL JSON Nativo: Para almacenar los metadatos dinámicos variables extraídos por Gemini (que varían según el tipo de documento: Contratos, Facturas o Hojas de Vida), se utiliza la columna nativa **metadata_json** de tipo **JSON** en MySQL. Esto elimina la necesidad de tablas escasas, manteniendo la flexibilidad de un enfoque NoSQL con el rigor relacional e integridad referencial de MySQL gestionado con HeidiSQL.

DOCUMIND — DICCIONARIO DE DATOS

Especificación técnica de persistencia de datos (MySQL Relacional & Pinecone Vectorial)

Almacena las cuentas de usuario y credenciales de acceso del personal autorizado.

Campo	Tipo Lógico	Restricciones	MySQL / HeidiSQL	Descripción Funcional
id	BIGINT	PK, AUTO_INCREMENT	BIGINT UNSIGNED	Llave primaria única de identificación de cada usuario.
nombre	VARCHAR	NOT NULL, Max 100	VARCHAR(100)	Nombre completo del usuario analista o administrador.
email	VARCHAR	NOT NULL, UNIQUE	VARCHAR(150)	Correo institucional de acceso (se utiliza para el Login).
password_hash	VARCHAR	NOT NULL, Max 255	VARCHAR(255)	Contraseña encriptada en backend utilizando bcrypt.
rol	ENUM	NOT NULL	ENUM('ADMIN', 'LEGAL', 'FINANCIERO', 'RECLUTADOR')	Rol operativo para control de accesos (RBAC).
creado_en	TIMESTAMP	NOT NULL, DEFAULT NOW	TIMESTAMP	Fecha y hora exacta del registro del usuario.

TABLA: REPOSITORIOS

Define las carpetas lógicas que aíslan los documentos por área de negocio.

Campo	Tipo Lógico	Restricciones	MySQL / HeidiSQL	Descripción Funcional
id	BIGINT	PK, AUTO_INCREMENT	BIGINT UNSIGNED	Llave primaria de identificación del repositorio/carpeta.
nombre	VARCHAR	NOT NULL, Max 100	VARCHAR(100)	Nombre de la carpeta lógica (ej. 'Contratos Q3').
descripcion	TEXT	NULL	TEXT	Breve descripción sobre el contenido o propósito de la carpeta.
departamento	VARCHAR	NOT NULL, Max 50	VARCHAR(50)	Departamento operativo asociado (Legal, Finanzas o Selección).
usuario_id	BIGINT	FK (usuarios.id)	BIGINT UNSIGNED	ID del usuario creador y administrador de la carpeta.
creado_en	TIMESTAMP	NOT NULL, DEFAULT NOW	TIMESTAMP	Fecha y hora exacta de creación del repositorio.

DOCUMIND — DICCIONARIO DE DATOS

Especificación técnica de persistencia de datos (MySQL Relacional & Pinecone Vectorial)

Entidad core que registra los archivos ingestados físicamente y procesados por IA.

Campo	Tipo Lógico	Restricciones	MySQL / HeidiSQL	Descripción Funcional
id	BIGINT	PK, AUTO_INCREMENT	BIGINT UNSIGNED	Llave primaria de identificación del archivo cargado.
nombre_archivo	VARCHAR	NOT NULL, Max 255	VARCHAR(255)	Nombre original del archivo (ej. 'factura_0912.pdf').
url_descarga	TEXT	NOT NULL	TEXT	URL segura y persistente de descarga en el almacenamiento en la nube.
tipo_formato	VARCHAR	NOT NULL, Max 10	VARCHAR(10)	Formato original del archivo físico (PDF, DOCX, TXT).
tamaño_bytes	BIGINT	NOT NULL	BIGINT	Tamaño físico del archivo en bytes (límite estricto de 15MB).
categoria_detectada	VARCHAR	NULL, Max 50	VARCHAR(50)	Clasificación por IA: 'Contrato', 'Factura' o 'Hoja de Vida'.
score_confianza	DECIMAL	NULL	DECIMAL(5,2)	Score de acierto retornado por el clasificador Gemini (0.00% a 100.00%).
resumen_ia	TEXT	NULL	TEXT	Síntesis ejecutiva generada automáticamente por la IA (máximo 150 palabras).
estado_procesamiento	ENUM	NOT NULL, DEFAULT 'PENDIENTE'	ENUM('PENDIENTE', 'PROCESANDO', 'COMPLETADO', 'ERROR')	Estado actual del documento dentro de la cola del pipeline de IA.
repositorio_id	BIGINT	FK (repositorios.id)	BIGINT UNSIGNED	Llave foránea que asocia el documento a su carpeta lógica.
creado_en	TIMESTAMP	NOT NULL, DEFAULT NOW	TIMESTAMP	Fecha y hora de ingesta e inicio de procesamiento.

DOCUMIND — DICCIONARIO DE DATOS

Especificación técnica de persistencia de datos (MySQL Relacional & Pinecone Vectorial)

Almacena los metadatos específicos de cada tipo de archivo (Contratos, Facturas o CVs) extraídos por Gemini.

Campo	Tipo Lógico	Restricciones	MySQL / HeidiSQL	Descripción Funcional
id	BIGINT	PK, AUTO_INCREMENT	BIGINT UNSIGNED	Llave primaria única del registro de metadatos.
documento_id	BIGINT	FK (documentos.id)	BIGINT UNSIGNED	Llave foránea vinculada de forma estricta (1:1) al documento.
metadata_json	JSON	NOT NULL	JSON	Esquema JSON dinámico y estructurado con metadatos específicos por tipo.

Estándar del campo metadata_json según la categoría:

- **Contratos:** { 'firmantes': ['Empresa A', 'Empresa B'], 'vigencia': '12 meses', 'penalizaciones': '10% por mora' }
- **Facturas:** { 'emisor_nit': '800.123.456-1', 'valor_total': 158500.00, 'impuestos': 25300.00, 'fecha_vencimiento': '2026-10-15' }
- **Hojas de Vida:** { 'tecnologias_clave': ['React', 'Python', 'MySQL'], 'experiencia_años': 4, 'ultimo_titulo': 'Tecnólogo en Desarrollo' }

TABLA: LOGS_ERRORES

Guarda el registro de errores del sistema y de la IA, visualizado en el Dashboard por el TI.

Campo	Tipo Lógico	Restricciones	MySQL / HeidiSQL	Descripción Funcional
id	BIGINT	PK, AUTO_INCREMENT	BIGINT UNSIGNED	Llave primaria del log de auditoría técnica.
documento_id	BIGINT	FK (documentos.id), NULLABLE	BIGINT UNSIGNED	ID del documento asociado que causó el fallo, si aplica.
severidad	ENUM	NOT NULL	ENUM('INFO', 'WARNING', 'ERROR', 'CRITICAL')	Categoría de severidad del evento de sistema para filtrado.
mensaje_error	TEXT	NOT NULL	TEXT	Explicación clara del error (ej. 'Gemini API limit reached').
stack_trace	TEXT	NULL	TEXT	Traza detallada del error del backend para depuración de TI.
creado_en	TIMESTAMP	NOT NULL, DEFAULT NOW	TIMESTAMP	Fecha y hora exacta del reporte del error.

DOCUMIND — DICCIONARIO DE DATOS

Especificación técnica de persistencia de datos (MySQL Relacional & Pinecone Vectorial)

Para dar soporte a las búsquedas semánticas y la recuperación de información (RAG), el pipeline segmenta el texto plano de los archivos en fragmentos lógicos (chunks) de 1000 caracteres con 200 de solapamiento. Cada fragmento se convierte en un vector denso utilizando el modelo **text-embedding-004** de Google Gemini y se indexa en Pinecone.

Campo / Metadata	Tipo Lógico	Pinecone Native	Mapeo / Propósito
id	String / UUID	String (ID)	ID único del vector, estructurado bajo el formato: doc_[documento_id]_chunk_[index].
values	Vector (768)	Array (Float32)	Embeddings numéricos generados por text-embedding-004 (768 dimensiones de precisión).
metadata.documento_id	BIGINT	Integer / Metadata	Llave foránea conceptual que mapea el vector con la tabla 'documentos' de MySQL.
metadata.text_chunk	TEXT	String / Metadata	Fragmento de texto original almacenado de forma directa para alimentar el prompt de Gemini.
metadata.page_num	INTEGER	Integer / Metadata	Número de página exacto del archivo de origen donde se encuentra el fragmento.

3. Certificación de Integridad Relacional y de IA

La arquitectura de persistencia de **DocuMind** garantiza la integridad referencial completa de la aplicación, enlazando directamente las cuentas de analistas con sus repositorios lógicos de negocio y los archivos cargados. La vinculación indirecta de metadatos entre la base de datos MySQL (HeidiSQL) y Pinecone Vector DB previene de manera absoluta las alucinaciones por IA, permitiendo al sistema validar la existencia de cada documento y citar fielmente el nombre de los archivos origen y páginas recuperadas en cada consulta del Chat de IA.