

DOCUMIND V1.0 — PLAN DE IMPLEMENTACIÓN Y DESPLIEGUE EN LA NUBE

ENTREGABLE OFICIAL 05 — TECNOLOGÍA EN DESARROLLO DE SOFTWARE

Asignatura: Proyecto Integrador — Desarrollo de Aplicaciones Empresariales (VI Semestre)

Docente Evaluador: Ing. Wilson Castaño Galviz

Institución: Unidades Tecnológicas de Santander (UTS)

Integrantes del Equipo: Grupo de Desarrollo DocuMind V1.0

Fecha de Entrega: Segundo Semestre - 2026

Estado del Entregable: Fase V (Aprobado y Documentado)

Resumen Ejecutivo de la Fase V: Este plan detalla la arquitectura de despliegue, configuración e infraestructura segura del sistema DocuMind. Se formalizan las directrices para migrar la plataforma del entorno local de desarrollo (levantado con Antigravity Pro y HeidiSQL) a un ambiente de producción robusto en la nube (Render, Vercel, MySQL Cloud y Pinecone Vector DB). Asimismo, se establece una política rigurosa de copias de seguridad (backups) automáticas para la base de datos de MySQL que garantice de forma absoluta la resiliencia y el respaldo de la información documental de la compañía.

1. Arquitectura de Infraestructura y Despliegue Cloud

Para dar soporte de producción a DocuMind V1.0 y garantizar la mitigación total de riesgos de indisponibilidad de APIs, se ha seleccionado una **arquitectura de nube híbrida multi-proveedor** de bajo costo y alta fiabilidad, maximizando los beneficios de las capas gratuitas (free-tier) para fines académicos de la UTS. Esta estructura divide de forma física y aislada la capa de cliente, la capa de negocio, el motor relacional de datos, el repositorio vectorial y el sistema cognitivo de IA.

Componente / Capa	Plataforma Cloud	Protocolo / Enlace	Rol Funcional
Frontend (React)	Vercel / Netlify	HTTPS (SSL/TLS 1.3)	Distribución ágil mediante CDN global. Conexión continua con rama main de GitHub.
Backend (Express)	Render Web Services	HTTPS API REST	Servidor runtime contenedorizado. Orquesta el pipeline de Gemini y MySQL.
Relational DB	Aiven / Railway Cloud	MySQL TCP (Puerto 3306)	MySQL nativo administrado. Almacena usuarios, carpetas y metadatos JSON.
Vector DB	Pinecone Cloud DB	GRPC / HTTPS SDK	Índice 'documind-index' con embeddings vectoriales de 768 dimensiones.
Servicios de IA	Google Cloud AI	HTTPS REST API Key	Modelos gemini-1.5-flash y text-embedding-004 para el pipeline RAG.
Cloud Storage	AWS S3 / Firebase	HTTPS Secure URL	Almacenamiento físico de los archivos PDF, DOCX y TXT originales.

1.1 Justificación del Aislamiento de Capas

El aislamiento de las capas garantiza que el sistema mantenga una tolerancia a fallos elevada. Si el motor de Inteligencia Artificial de Google Gemini experimenta latencia o caídas momentáneas, el backend de Express.js capturará el error e insertará un log de severidad WARNING o ERROR en la base de datos de MySQL, evitando que el frontend en React colapse. Los usuarios podrán seguir listando sus carpetas y descargando sus archivos físicos gracias a que la persistencia relacional en MySQL y física en Cloud Storage operan de manera independiente.

2. Requisitos del Sistema en el Ambiente de Implementación

Para garantizar la viabilidad técnica de DocuMind en producción y un rendimiento que cumpla con el requerimiento no funcional **RNF-02 (Latencia menor a 8 segundos en respuestas complejas)**, se definen los siguientes requerimientos de hardware y software para el servidor backend, motor de persistencia relacional y dispositivo cliente:

Entorno	Requisito Mínimo de Hardware	Requisito Mínimo de Software	Finalidad Técnica
Servidor API (Express)	1 vCPU Virtual, 512 MB de Memoria RAM, 2 GB SSD temporal.	Node.js runtime v18.16.0 LTS o superior, Express framework v4.18.	Ejecutar la API REST y procesar archivos binarios (Multer y text-parsers).
Servidor MySQL (Cloud)	1 vCPU, 1 GB de RAM dedicada, 10 GB SSD de almacenamiento.	MySQL Community Server v8.0.30+, motor de almacenamiento InnoDB.	Mantener integridad relacional, índices rápidos y soporte para columnas JSON.
Cliente Operativo	CPU Dual Core a 2.0 GHz, 4 GB RAM, conexión a internet.	Navegadores modernos compatible HTML5: Chrome, Safari, Firefox o Edge.	Cargar y visualizar el frontend, dashboard de Recharts e interactuar con el Chat.

3. Variables de Entorno y Configuración Segura (.env)

En cumplimiento con el requisito obligatorio de seguridad **RNF-01 (Seguridad de API Keys)** y para mitigar el riesgo crítico **AR-03 (Exposición de Credenciales)**, la aplicación maneja sus secretos estrictamente mediante variables de entorno configuradas directamente en el panel de control de Render (Web Service Settings) y de Vercel. Queda terminantemente prohibido quemar contraseñas en duro o subir el archivo .env local al repositorio público de GitHub.

```
# =====
# CONFIGURACIÓN DE PRODUCCIÓN DE DOCUMIND (BACKEND EN RENDER)
# =====
PORT=10000
NODE_ENV=production
JWT_SECRET=Uts_VI_Semestre_Secure_Sha256_Token_DocuMind_Production_2026_Crypto

# CREDENCIALES DE PERSISTENCIA RELACIONAL (MYSQL CLOUD - AIVEN)
DB_HOST=mysql-production-documind-uts.aivencloud.com
DB_PORT=25064
DB_USER=avnadmin
DB_PASS=AVNS_mY7xY_tu_clave_altamente_segura_aiven_mysql_2026
DB_NAME=documind_production

# CONFIGURACIÓN DE INTELIGENCIA ARTIFICIAL (GOOGLE GEMINI API)
GEMINI_API_KEY=AiZaSyA_Production_Key_Google_AI_Studio_Gemini_Flash_1.5
```

```
# CONFIGURACIÓN DE BASE VECTORIAL (PINECONE VECTOR DATABASE)
PINECONE_API_KEY=pcsk_987654321_Pinecone_Production_Enterprise_Secret_Key
PINECONE_INDEX_NAME=documind-index
```

Nota de Seguridad en Producción: En el ambiente cliente (React en Vercel), la única variable de entorno expuesta es `VITE_API_URL`, la cual apunta de forma segura al endpoint HTTPS del backend en Render. El cliente desconoce por completo las claves API de Gemini, Pinecone o de la base de datos de MySQL, blindando el sistema de ataques por ingeniería inversa.

4. Proceso de Instalación y Despliegue en Producción

Para garantizar la reproducibilidad completa del sistema ante los evaluadores de la UTS, se documenta la secuencia lógica y comandos de terminal obligatorios para desplegar la plataforma desde cero:

Paso	Fase del Proceso	Comandos o Herramientas	Resultado de Verificación
Paso 1	Preparación del Repositorio	git init git add . git commit -m 'Release v1.0'	Repositorio de GitHub activo con estructura limpia, excluyendo node_modules y .env en .gitignore.
Paso 2	Despliegue del MySQL Cloud	Consola HeidiSQL / Aiven Cloud Console	Base de datos remota 'documind_production' inicializada mediante la ejecución del script DDL.
Paso 3	Índice Vectorial	Consola Web de Pinecone (app.pinecone.io)	Índice 'documind-index' creado: 768 Dimensiones, Métrica Cosine, Serverless Starter.
Paso 4	Servidor Backend	Render Cloud Console -> Create Web Service	Web Service enlazado a GitHub, variables inyectadas y servidor Express escuchando en puerto 10000.
Paso 5	Compilación Frontend	Vercel Cloud Console -> Import Project	SPA construida exitosamente con Vite; asignada variable VITE_API_URL del backend.
Paso 6	Sincronización	Navegador Web (URL de producción)	Acceso seguro mediante HTTPS. Login y dashboard listando estadísticas en tiempo real.

4.1. Verificación Inicial del Índice en Pinecone

El SDK de Pinecone en Node.js requiere que el índice se encuentre previamente aprovisionado y en estado activo. Durante la inicialización del backend en Render, el sistema ejecutará una llamada automática de verificación utilizando el método `index.describeIndexStats()`. Si la base vectorial responde con la dimensionalidad exacta de 768 y el índice se encuentra activo, se habilitará la cola de carga documental, garantizando la consistencia del pipeline RAG.

5. Estrategia de Respaldo y Recuperación de MySQL

La pérdida accidental de datos estructurados, históricos o metadatos extraídos por IA representa una amenaza grave de negocio. Para mitigar este riesgo de manera contundente y asegurar el cumplimiento de las políticas de auditoría del proyecto integrador, se define una **estrategia de respaldo periódico automatizado** combinando copias lógicas semanales y diarias en almacenamiento en frío aislado lógicamente de la base de datos de producción.

Tipo de Respaldo	Periodicidad	Herramienta	Destino / Medio de Respaldo
Respaldo Lógico Completo	Diario (02:00 AM, horas de bajo tráfico)	mysqldump utility (CLI)	Archivo comprimido (.sql.gz) en AWS S3 Bucket con ciclo de vida de 30 días.
Backup Incremental	Cada 6 horas	MySQL Binary Log Replication	Almacenamiento de réplicas en volumen físico independiente en zona cloud secundaria.
Respaldo Manual	Antes de cada despliegue o release de código	Exportación HeidiSQL (GUI)	Almacenamiento cifrado local del desarrollador líder del proyecto.

5.1 Script Bash Automatizado de Respaldo

A continuación, se presenta el código del script bash ejecutable en producción (por ejemplo, en un cronjob de un servidor de soporte o servidor administrador de TI) para automatizar la extracción diaria de los datos lógicos de DocuMind [cite: 8]:

```
#!/bin/bash
# =====
# SCRIPT DE RESPALDO AUTOMÁTICO DE MYSQL - DOCUMIND PRODUCTION [cite: 8]
# =====
DB_HOST="mysql-production-documind-uts.aivencloud.com"
DB_PORT="25064"
DB_USER="avnadmin"
DB_PASS="AVNS_mY7xY_tu_clave_altamente_segura_aiven_mysql_2026"
DB_NAME="documind_production"
BACKUP_DIR="/workspace/backups"
DATE=$(date +%Y-%m-%d_%H%M%S)
FILE_NAME="${BACKUP_DIR}/documind_production_backup_${DATE}.sql"

# Asegurar que exista el directorio de destino
mkdir -p ${BACKUP_DIR}

echo "Iniciando respaldo de base de datos relacional de DocuMind..."
mysqldump -h ${DB_HOST} -P ${DB_PORT} -u ${DB_USER} -p${DB_PASS} ${DB_NAME} > ${FILE_NAME}

if [ $? -eq 0 ]; then
echo "Dump de base de datos generado exitosamente. Comprimiendo archivo..."
gzip ${FILE_NAME}
echo "Respaldo finalizado con éxito: ${FILE_NAME}.gz"
else
echo "ERROR CRÍTICO: El comando mysqldump falló al conectarse a MySQL Cloud."
```

```
exit 1  
fi
```

5.2 Protocolo de Restauración ante Emergencias

En caso de corrupción de datos relacionales, fallos graves de integridad o eliminación accidental de un repositorio completo de negocio, se activará el plan de contingencia de TI de recuperación en un plazo menor a 2 horas operativas [cite: 8]:

1. **Aislamiento preventivo:** Se desactiva temporalmente el backend en Render cambiando la variable de entorno de producción a modo de mantenimiento, impidiendo nuevas escrituras en MySQL.
2. **Aprovisionamiento:** Se descarga el archivo de respaldo comprimido más reciente desde el bucket de seguridad de AWS S3 y se descomprime en el servidor administrativo.
3. **Ejecución de Limpieza:** Se realiza un drop preventivo de la base de datos corrupta y se crea una estructura limpia desde HeidiSQL.
4. **Restauración:** Se ejecuta el comando de inyección de consola mysql: `mysql -h [Host] -u [User] -p[Password] [DB_Name] < backup_descomprimido.sql`
5. **Validación y Arranque:** Se ejecutan consultas de prueba, se reactiva el backend de Express en Render y se valida la coherencia relacional en el Dashboard de monitoreo.

6. Plan de Mantenimiento y Monitoreo de APIs

Para asegurar la estabilidad técnica prolongada de la solución a lo largo del tiempo, se define un plan de mantenimiento preventivo y de monitoreo de cuotas de servicios cognitivos de Inteligencia Artificial que comprende los siguientes lineamientos: 1. **Auditoría Mensual de Variables de Entorno:** Rotación obligatoria de la variable JWT_SECRET y actualización del token API de Google Gemini en la consola Cloud para mitigar riesgos de robo de identidad o consumos no autorizados. 2. **Monitoreo de Logs en Express:** Revisión periódica de la tabla logs_errores en MySQL. Los incidentes graves (severidad CRITICAL o ERROR), tales como cuotas de API keys superadas o fallos graves de estructura del parser de documentos, dispararán alertas automáticas en el dashboard. 3. **Mantenimiento Correctivo de Datos:** Depuración semestral de fragmentos o chunks vectoriales huérfanos en Pinecone que no posean su correspondiente registro físico activo en la tabla documentos de MySQL, reduciendo costos de almacenamiento en frío.

Grupo de Desarrollo DocuMind V1.0
Tecnología en Desarrollo de Software
Responsable del Despliegue Técnico

Ing. Wilson Castaño Galviz
Docente Evaluador del Proyecto - UTS
Aprobación de Fase de Implementación