

DOCUMIND V1.0 PLAN DE IMPLEMENTACIÓN Y DESPLIEGUE EN LA NUBE

ENTREGABLE OFICIAL 05 TECNOLOGÍA EN DESARROLLO DE SOFTWARE

Asignatura: Proyecto Integrador Desarrollo de Aplicaciones Empresariales (VI Semestre)

Docente Evaluador: Ing. Wilson Castaño Galviz

Institución: Unidades Tecnológicas de Santander (UTS)

Integrantes del Equipo: Grupo de Desarrollo DocuMind V1.0

Fecha de Entrega: Segundo Semestre - 2026

Estado del Entregable: Fase V (Aprobado y Documentado)

Resumen Ejecutivo de la Fase V: Este plan detalla la arquitectura de despliegue, configuración e infraestructura segura del sistema DocuMind. Se formalizan las directrices para migrar la plataforma del entorno local de desarrollo (levantado con Antigravity Pro y HeidiSQL) a un ambiente de producción robusto en la nube (Render, Vercel, MySQL Cloud y Pinecone Vector DB). Asimismo, se establece una política rigurosa de copias de seguridad (backups) automáticas para la base de datos de MySQL que garantice de forma absoluta la resiliencia y el respaldo de la información documental de la compañía.

1. Arquitectura de Infraestructura y Despliegue Cloud

Para dar soporte de producción a DocuMind V1.0 y garantizar la mitigación total de riesgos de indisponibilidad de APIs, se ha seleccionado una arquitectura de nube híbrida multi-proveedor de bajo costo y alta fiabilidad, maximizando los beneficios de las capas gratuitas (free-tier) para fines académicos de la UTS. Esta estructura divide de forma física y aislada la capa de cliente, la capa de negocio, el motor relacional de datos, el repositorio vectorial y el sistema cognitivo de IA.

Componente / Capa	Plataforma Cloud	Protocolo / Enlace	Rol Funcional
Frontend (React)	Vercel / Netlify	HTTPS (SSL/TLS 1.3)	Distribución global mediante CDN global. Conexión continua con rama main de GitHub.
Backend (Express)	Render Web Services	HTTPS API REST	Servidor runtime contenedorizado. Orquesta el pipeline de Gemini y MySQL.
Relational DB	Aiven / Railway Cloud	MySQL TCP (Puerto 3306)	MySQL nativo administrado. Almacena usuarios, carpetas y metadatos JSON.
Vector DB	Pinecone Cloud DB	GRPC / HTTPS SDK	Índice 'documind-index' con embeddings vectoriales de 768 dimensiones.
Servicios de IA	Google Cloud AI	HTTPS REST API Key	Modelos gemini-1.5-flash y text-embedding-004 para el pipeline RAG.
Cloud Storage	AWS S3 / Firebase	HTTPS Secure URL	Almacenamiento físico de los archivos PDF, DOCX y TXT originales.

1.1 Justificación del Aislamiento de Capas

El aislamiento de las capas garantiza que el sistema mantenga una tolerancia a fallos elevada. Si el motor de Inteligencia Artificial de Google Gemini experimenta latencia o caídas momentáneas, el backend de Express.js captura el error e inserta un log de severidad WARNING o ERROR en la base de datos de MySQL, evitando que el frontend en React colapse. Los usuarios podrán seguir listando sus carpetas y descargando sus archivos físicos gracias a que la persistencia relacional en MySQL y física en Cloud Storage operan de manera independiente.

2. Requisitos del Sistema en el Ambiente de Implementación

Para garantizar la viabilidad técnica de DocuMind en producción y un rendimiento que cumpla con el requerimiento no funcional RNF-02 (Latencia menor a 8 segundos en respuestas complejas), se definen los siguientes requerimientos de hardware y software para el servidor backend, motor de persistencia relacional y dispositivo cliente:

Entorno	Requisito Mínimo de Hardware	Requisito Mínimo de Software	Finalidad Técnica
Servidor API (Express)	1 vCPU Virtual, 512 MB de Memoria RAM, 2 GB SSD temporal.	Node.js runtime v18.16.0 LTS o superior, Express framework v4.18.	Ejecutar la API REST y procesar archivos binarios (Multer y text-parsers).
Servidor MySQL (Cloud)	1 vCPU, 1 GB de RAM dedicada, 10 GB SSD de almacenamiento.	MySQL Community Server v8.0.30+, motor de almacenamiento InnoDB.	Mantener integridad relacional, índices rápidos y soporte para columnas JSON.
Cliente Operativo	CPU Dual Core a 2.0 GHz, 4 GB RAM, conexión a internet.	Navegadores modernos compatible HTML5: Chrome, Safari, Firefox o Edge.	Cargar y visualizar el frontend, dashboard de Recharts e interactuar con el Chat.

3. Variables de Entorno y Configuración Segura (.env)

En cumplimiento con el requisito obligatorio de seguridad RNF-01 (Seguridad de API Keys) y para mitigar el riesgo crítico AR-03 (Exposición de Credenciales), la aplicación maneja sus secretos estrictamente mediante variables de entorno configuradas directamente en el panel de control de Render (Web Service Settings) y de Vercel. Queda terminantemente prohibido quemar contraseñas en duro o subir el archivo .env local al repositorio público de GitHub.

```
# =====
# CONFIGURACIÓN DE PRODUCCIÓN DE DOCUMIND (BACKEND EN RENDER)
# =====
PORT=10000
NODE_ENV=production
JWT_SECRET=Uts_VI_Semestre_Secure_Sha256_Token_DocuMind_Production_2026_Crypto

# CREDENCIALES DE PERSISTENCIA RELACIONAL (MYSQL CLOUD - AIVEN)
DB_HOST=mysql-production-documind-uts.aivencloud.com
DB_PORT=25064
DB_USER=avnadmin
DB_PASS=AVNS_mY7xY_tu_clave_altamente_segura_aiven_mysql_2026
DB_NAME=documind_production

# CONFIGURACIÓN DE INTELIGENCIA ARTIFICIAL (GOOGLE GEMINI API)
GEMINI_API_KEY=AiZaSyA_Production_Key_Google_AI_Studio_Gemini_Flash_1.5
```

```
# CONFIGURACIÓN DE BASE VECTORIAL (PINECONE VECTOR DATABASE)
PINECONE_API_KEY=pcsk_987654321_Pinecone_Production_Enterprise_Secret_Key
PINECONE_INDEX_NAME=documind-index
```

Nota de Seguridad en Producción: En el ambiente cliente (React en Vercel), la única variable de entorno expuesta es *VITE_API_URL*, la cual apunta de forma segura al endpoint HTTPS del backend en Render. El cliente desconoce por completo las claves API de Gemini, Pinecone o de la base de datos de MySQL, blindando el sistema de ataques por ingeniería inversa.

4. Proceso de Instalación y Despliegue en Producción

Para garantizar la reproducibilidad completa del sistema ante los evaluadores de la UTS, se documenta la secuencia lógica y comandos de terminal obligatorios para desplegar la plataforma desde cero:

Paso	Fase del Proceso	Comandos o Herramientas	Resultado de Verificación
Paso 1	Preparación del Repositorio	git init git add . git commit -m 'Release v1.0'	Repositorio de GitHub activo con estructura limpia, excluyendo node_modules y .env en .gitignore.
Paso 2	Despliegue del MySQL Cloud	Consola HeidiSQL / Aiven Cloud Console	Base de datos remota 'documind_production' inicializada mediante la ejecución del script DDL.
Paso 3	Índice Vectorial	Consola Web de Pinecone (app.pinecone.io)	Índice 'documind-index' creado: 768 Dimensiones, Métrica Cosine, Serverless Starter.
Paso 4	Servidor Backend	Render Cloud Console -> Create Web Service	Web Service enlazado a GitHub, variables inyectadas y servidor Express escuchando en puerto 10000.
Paso 5	Compilación Frontend	Vercel Cloud Console -> Import Project	SPA construida exitosamente con Vite; asignada variable VITE_API_URL del backend.
Paso 6	Sincronización	Navegador Web (URL de producción)	Acceso seguro mediante HTTPS. Login y dashboard listando estadísticas en tiempo real.

4.1. Verificación Inicial del índice en Pinecone

El SDK de Pinecone en Node.js requiere que el índice se encuentre previamente aprovisionado y en estado activo. Durante la inicialización del backend en Render, el sistema ejecuta una llamada automática de verificación utilizando el método `index.describeIndexStats()`. Si la base vectorial responde con la dimensionalidad exacta de 768 y el índice se encuentra activo, se habilita la cola de carga documental, garantizando la consistencia del pipeline RAG.

5. Estrategia de Respaldo y Recuperación de MySQL

La pérdida accidental de datos estructurados, históricos o metadatos extraídos por IA representa una amenaza grave de negocio. Para mitigar este riesgo de manera contundente y asegurar el cumplimiento de las políticas de auditoría del proyecto integrador, se define una **estrategia de respaldo periódico automatizado** combinando copias lógicas semanales y diarias en almacenamiento en frío aislado lógicamente de la base de datos de producción.

Tipo de Respaldo	Periodicidad	Herramienta	Destino / Medio de Respaldo
Respaldo Lógico Completo	Diario (02:00 AM, horas de bajo tráfico)	mysqldump utility (CLI)	Archivo comprimido (.sql.gz) en AWS S3 Bucket con ciclo de vida de 30 días.
Backup Incremental	Cada 6 horas	MySQL Binary Log Replication	Almacenamiento de réplicas en volumen físico independiente en zona cloud secundaria.
Respaldo Manual	Antes de cada despliegue o release de código	Exportación HeidiSQL (GUI)	Almacenamiento cifrado local del desarrollador líder del proyecto.

5.1 Script Bash Automatizado de Respaldo

A continuación, se presenta el código del script bash ejecutable en producción (por ejemplo, en un cronjob de un servidor de soporte o servidor administrador de TI) para automatizar la extracción diaria de los datos lógicos de DocuMind [cite: 8]:

```
#!/bin/bash
# =====
# SCRIPT DE RESPALDO AUTOMÁTICO DE MYSQL - DOCUMIND PRODUCTION [cite: 8]
# =====
DB_HOST="mysql-production-documind-uts.aivencloud.com"
DB_PORT="25064"
DB_USER="avnadmin"
DB_PASS="AVNS_mY7xY_tu_clave_altamente_segura_aiven_mysql_2026"
DB_NAME="documind_production"
BACKUP_DIR="/workspace/backups"
DATE=$(date +%Y-%m-%d_%H%M%S)
FILE_NAME="${BACKUP_DIR}/documind_production_backup_${DATE}.sql"

# Asegurar que exista el directorio de destino
mkdir -p ${BACKUP_DIR}

echo "Iniciando respaldo de base de datos relacional de DocuMind..."
mysqldump -h ${DB_HOST} -P ${DB_PORT} -u ${DB_USER} -p${DB_PASS} ${DB_NAME} > ${FILE_NAME}

if [ $? -eq 0 ]; then
echo "Dump de base de datos generado exitosamente. Comprimiendo archivo..."
gzip ${FILE_NAME}
echo "Respaldo finalizado con éxito: ${FILE_NAME}.gz"
else
echo "ERROR CRÍTICO: El comando mysqldump falló al conectarse a MySQL Cloud."
```

```
exit 1  
fi
```

5.2 Protocolo de Restauración ante Emergencias

En caso de corrupción de datos relacionales, fallos graves de integridad o eliminación accidental de un repositorio completo de negocio, se activará el plan de contingencia de TI de recuperación en un plazo menor a 2 horas operativas [cite: 8]:

1. **Aislamiento preventivo:** Se desactiva temporalmente el backend en Render cambiando la variable de entorno de producción a modo de mantenimiento, impidiendo nuevas escrituras en MySQL.
2. **Aprovisionamiento:** Se descarga el archivo de respaldo comprimido más reciente desde el bucket de seguridad de AWS S3 y se descomprime en el servidor administrativo.
3. **Ejecución de Limpieza:** Se realiza un drop preventivo de la base de datos corrupta y se crea una estructura limpia desde HeidiSQL.
4. **Restauración:** Se ejecuta el comando de inyección de consola mysql: `mysql -h [Host] -u [User] -p[Password] [DB_Name] < backup_descomprimido.sql`
5. **Validación y Arranque:** Se ejecutan consultas de prueba, se reactiva el backend de Express en Render y se valida la coherencia relacional en el Dashboard de monitoreo.

6. Plan de Mantenimiento y Monitoreo de APIs

Para asegurar la estabilidad t cnica prolongada de la soluci n a lo largo del tiempo, se define un plan de mantenimiento preventivo y de monitoreo de cuotas de servicios cognitivos de Inteligencia Artificial que comprende los siguientes lineamientos: 1. **Auditor a Mensual de Variables de Entorno:** Rotaci n obligatoria de la variable JWT_SECRET y actualizaci n del token API de Google Gemini en la consola Cloud para mitigar riesgos de robo de identidad o consumos no autorizados. 2. **Monitoreo de Logs en Express:** Revisi n peri dica de la tabla logs_errores en MySQL. Los incidentes graves (severidad CRITICAL o ERROR), tales como cuotas de API keys superadas o fallos graves de estructura del parser de documentos, disparar n alertas autom ticas en el dashboard. 3. **Mantenimiento Correctivo de Datos:** Depuraci n semestral de fragmentos o chunks vectoriales hu rfanos en Pinecone que no posean su correspondiente registro f sico activo en la tabla documentos de MySQL, reduciendo costos de almacenamiento en fr o.

Grupo de Desarrollo DocuMind V1.0
Tecnolog a en Desarrollo de Software
Responsable del Despliegue T cnico

Ing. Wilson Casta o Galviz
Docente Evaluador del Proyecto - UTS
Aprobaci n de Fase de Implementaci n